

LAPORAN TEKNIS PROYEK

StreetWatch

Sistem Deteksi Jalan Berlubang Berbasis Computer Vision

Problem Discovery ▶ Data Wrangling ▶ EDA ▶ Feature Engineering
Visualisasi ▶ Dashboard Streamlit ▶ A/B Testing ▶ YOLO Export

Tim Pengembang

Della Nurizki - CDCC006D6X0173

Moch. Alif Budi Setyaman - CDCC185D6Y0406

Dataset: RDD2022 India Pothole (Kaggle — vidishbijalwan/rdd2022-india-pothole-d40)

Tools: Python · Pandas · OpenCV · Albumentations · Streamlit · Plotly · scikit-learn

Juni 2026

1. Pendahuluan

1.1 Latar Belakang

Kondisi jalan berlubang merupakan salah satu permasalahan infrastruktur yang secara langsung berdampak pada keselamatan, kenyamanan, dan mobilitas pengguna jalan. Proses identifikasi kerusakan jalan selama ini masih banyak dilakukan secara manual melalui laporan masyarakat atau inspeksi langsung oleh petugas, yang membutuhkan waktu, tenaga, dan biaya yang cukup besar.

Proyek StreetWatch hadir sebagai solusi berbasis computer vision untuk mengotomatisasi proses deteksi jalan berlubang. Dengan memanfaatkan dataset gambar jalan yang telah dianotasi secara akurat, proyek ini membangun pipeline lengkap mulai dari pengumpulan data, pembersihan, feature engineering, analisis eksplorasi, hingga persiapan data untuk pelatihan model deteksi objek berbasis YOLO.

1.2 Tujuan Proyek

Proyek ini bertujuan untuk:

- Membangun pipeline data wrangling yang terstruktur dan reproducible untuk dataset anotasi gambar jalan berlubang.
- Mendefinisikan dan menjawab pertanyaan bisnis yang dapat diukur (measurable business questions) menggunakan data yang tersedia.
- Mengembangkan fitur-fitur analitik tambahan (feature engineering) yang meningkatkan kualitas informasi dataset.
- Menyajikan insight melalui dashboard interaktif berbasis Streamlit yang dapat diakses oleh pemangku kepentingan non-teknis.
- Mempersiapkan dataset dalam format YOLO yang siap digunakan pada tahap pelatihan model object detection.

1.3 Tim & Dataset

Tim Pengembang	Della & Alif
Dataset	RDD2022 India Pothole — vidishbijalwan/rdd2022-india-pothole-d40 (Kaggle)
Format Anotasi	PASCAL VOC (XML) dengan label D40 / pothole
Tools Utama	Python, Pandas, OpenCV, Albumentations, Streamlit, Plotly, scikit-learn
Format Output	CSV (full + per split), YOLO .txt annotation, Dashboard Streamlit

2. Problem Discovery & Solusi Utama

2.1 Identifikasi Permasalahan

Analisis awal mengidentifikasi lima permasalahan utama yang berkaitan dengan kondisi jalan berlubang di Indonesia:

1. Proses identifikasi jalan berlubang masih banyak dilakukan secara manual dan tidak terstandarisasi.
2. Laporan kerusakan jalan dari masyarakat tidak selalu terdokumentasi dengan baik dan konsisten.
3. Jalan berlubang secara signifikan meningkatkan risiko kecelakaan dan kerusakan kendaraan.
4. Data kerusakan jalan belum dimanfaatkan secara optimal untuk pengambilan keputusan berbasis data.
5. Kualitas gambar jalan di lapangan sangat bervariasi, sehingga membutuhkan proses pra-pemrosesan yang baik.

2.2 Solusi Terpilih: StreetWatch

Dari kelima permasalahan tersebut, proyek ini memilih pendekatan computer vision sebagai solusi utama — yaitu mengembangkan StreetWatch, sebuah sistem deteksi jalan berlubang otomatis berbasis object detection.

Alasan Pemilihan Solusi

Dataset yang tersedia berupa gambar jalan dengan anotasi bounding box dalam format PASCAL VOC, yang secara langsung sesuai untuk pendekatan object detection. Solusi ini memungkinkan identifikasi pothole secara otomatis dari kamera dashcam atau kamera pengawas jalan raya tanpa intervensi manual.

2.3 Business Questions yang Dapat Diukur

Lima pertanyaan bisnis berikut ditetapkan untuk mengarahkan seluruh proses analisis:

ID	Topik	Pertanyaan
BQ1	Distribusi severity	Bagaimana distribusi tingkat keparahan jalan berlubang berdasarkan ukuran bounding box?
BQ2	Jumlah per gambar	Berapa banyak jumlah jalan berlubang yang terdapat pada setiap gambar?
BQ3	Distribusi ukuran	Bagaimana distribusi ukuran jalan berlubang berdasarkan bbox_area dan relative_size terhadap ukuran gambar?
BQ4	Kualitas gambar	Apakah terdapat gambar dengan kualitas rendah atau blur yang dapat memengaruhi kualitas data untuk pelatihan model?

ID	Topik	Pertanyaan
BQ5	Kesiapan dataset	Apakah dataset sudah cukup bersih dan siap digunakan untuk proses pelatihan model deteksi objek?

3. Data Wrangling

3.1 Data Gathering

Dataset diunduh secara otomatis menggunakan KaggleHub dengan perintah `kagglehub.dataset_download()`. Dataset mengandung gambar jalan (.jpg/.jpeg) beserta file anotasi XML dalam format PASCAL VOC.

- Struktur folder diidentifikasi secara otomatis menggunakan `os.walk()` untuk mencari direktori gambar dan anotasi.
- Label asli 'D40' (kode kerusakan RDD2022) dikonversi menjadi 'pothole' untuk konsistensi.
- Koordinat bounding box (xmin, ymin, xmax, ymax) di-parse dari XML ke dalam pandas DataFrame.

3.2 Data Assessing

Penilaian kualitas data dilakukan pada beberapa dimensi:

► Kelengkapan Data (Completeness)

- Pengecekan missing values pada seluruh kolom menggunakan `df.isnull().sum()`. Tidak ditemukan missing value setelah parsing XML.

► Duplikasi (Duplication)

- Pengecekan menggunakan `df.duplicated()`. Baris duplikat dihapus jika ditemukan.

► Validitas Bounding Box

- Bounding box dengan `bbox_width <= 0` atau `bbox_height <= 0` dihapus.
- Koordinat yang melampaui batas dimensi gambar di-clip ke nilai valid menggunakan `.clip()` dan `min()`.

► Outlier Detection

- Deteksi outlier pada `bbox_area` menggunakan metode IQR. Outlier TIDAK dihapus karena variasi ukuran pothole di dunia nyata memang beragam — ini merupakan keputusan domain yang disengaja.

3.3 Data Cleaning — Ringkasan

Aspek Cleaning	Tindakan	Hasil
Missing Values	Cek + hapus jika ada	0 missing values terdeteksi
Duplikasi	<code>df.drop_duplicates()</code>	0 baris duplikat
Bbox Tidak Valid	Hapus width/height ≤ 0	Semua bbox valid
Koordinat Keluar Batas	Clip ke dimensi gambar	Koordinat ternormalisasi

Label Kosong	Hapus baris tanpa label	Hanya label 'pothole'
Outlier bbox_area	Dideteksi, tetapi TIDAK dihapus	Dipertahankan (keputusan domain)

3.4 Image Quality Assessment (IQA)

Kualitas gambar dianalisis menggunakan metode Variance of Laplacian — sebuah teknik deteksi blur berbasis pengolahan citra.

Metode Blur Detection

Blur score dihitung dengan: (1) konversi gambar ke grayscale, (2) aplikasi operator Laplacian menggunakan `cv2.Laplacian(gray, cv2.CV_64F)`, (3) perhitungan variance dari hasil Laplacian. Semakin tinggi nilai variance, semakin tajam gambar. Threshold yang digunakan adalah 100.0.

Gambar dikategorikan ke dalam tiga kelompok kualitas:

- Blur — $\text{blur_score} < 100 \rightarrow$ DIHAPUS dari dataset latih
- Moderate — $100 \leq \text{blur_score} < 300 \rightarrow$ Dipertahankan dengan catatan
- Sharp — $\text{blur_score} \geq 300 \rightarrow$ Kualitas terbaik untuk training

. Feature Engineering

Delapan belas fitur tambahan dibuat dari data anotasi dasar untuk meningkatkan nilai informatif dataset. Tabel berikut merinci setiap fitur, formula pembuatannya, dan tujuan penggunaannya:

Fitur	Formula / Metode	Tipe	Tujuan
aspect_ratio	$\text{bbox_width} / \text{bbox_height}$	float	Menganalisis bentuk bounding box — pothole bulat vs. memanjang.
image_area	$\text{width} \times \text{height}$	integer	Luas gambar; denominator untuk normalisasi <code>relative_size</code> .
relative_size	$(\text{bbox_area} / \text{image_area}) \times 100$	float	Ukuran pothole relatif terhadap gambar; lebih adil dari <code>bbox_area</code> mentah.
center_x / center_y	$(\text{xmin} + \text{xmax}) / 2, (\text{ymin} + \text{ymax}) / 2$	float	Titik tengah objek; digunakan untuk spatial analysis dan konversi YOLO.
pothole_count	GROUP BY <code>image_name</code>	integer	Jumlah pothole per gambar; indikator kepadatan kerusakan.
class_id	Q33/Q66 threshold dari <code>bbox_area</code>	integer	Label kelas multi-class (0=Ringan, 1=Sedang, 2=Parah).
severity_label	Map dari <code>class_id</code>	string	Label teks keparahan untuk visualisasi dan filter dashboard.
severity_score	$(\text{relative_size}) + (\text{pothole_count} \times 0.5)$	float	Skor agregat keparahan; digunakan pada A/B Testing dan export dispatch.
blur_score	Variance of Laplacian (OpenCV)	float	Ketajaman gambar; gambar dengan skor < 100 dibuang dari training set.
image_quality	Threshold <code>blur_score</code>	string	Kategori kualitas: Blur (<100) / Moderate (100–300) / Sharp (≥300).
split	<code>train_test_split (70/15/15)</code>	string	Pembagian dataset; strategi berbasis <code>image_name</code> untuk cegah data leakage.
yolo_x/y/w/h	Normalisasi terhadap <code>width</code> & <code>height</code>	float	Format anotasi YOLO; nilai antara 0.0–1.0.

4.1 Sistem Klasifikasi Severity Multi-Class

Salah satu kontribusi utama feature engineering adalah konversi dari single-class (hanya 'pothole') menjadi multi-class (Ringan / Sedang / Parah) menggunakan thresholding berbasis distribusi data:

- Q33 (persentil ke-33 dari `bbox_area`) sebagai batas antara Ringan dan Sedang
- Q66 (persentil ke-66 dari `bbox_area`) sebagai batas antara Sedang dan Parah

Pendekatan berbasis kuantil ini menghasilkan distribusi kelas yang mendekati seimbang, sehingga mengurangi risiko class imbalance pada saat pelatihan model. Validasi konsistensi label dilakukan menggunakan fungsi `validate_severity_labels()` yang memeriksa apakah ada tumpang tindih antar kelas.

5. Exploratory Data Analysis (EDA)

EDA dilakukan dalam delapan sub-bagian, masing-masing dirancang untuk menjawab salah satu business question yang telah ditetapkan:

Sub	Topik EDA	Insight Utama
9.1	Distribusi Severity Label	Bar chart jumlah pothole per kategori (Ringan / Sedang / Parah). Dataset mendekati seimbang berkat thresholding berbasis kuantil (Q33 & Q66).
9.2	Distribusi Class ID	Bar chart distribusi class_id (0, 1, 2). Validasi konsistensi numerical label dengan severity_label.
9.3	Jumlah Pothole per Gambar	Histogram + KDE. Mayoritas gambar memiliki 1–3 pothole; sebagian kecil memiliki lebih dari 5 (gambar kompleks).
9.4	Distribusi Luas Bounding Box	Histogram bbox_area dan boxplot per severity. Membuktikan kategorisasi severity berdasarkan area sudah tepat.
9.5	Relative Size	Histogram dan boxplot relative_size per severity. Fitur ini lebih adil karena normalisasi terhadap ukuran gambar.
9.6	Kualitas Gambar (Blur Score)	Distribusi blur score + kategori Blur / Moderate / Sharp. Gambar dengan skor < 100 dibuang dari dataset latih.
9.7	Korelasi Fitur Numerik	Heatmap korelasi antar 8 fitur numerik. bbox_width, bbox_height, dan bbox_area berkorelasi tinggi (wajar).
9.8	Ringkasan Insight	Dataset siap secara teknis; variasi ukuran pothole tinggi; kualitas gambar cukup baik; split proporsional.

5.1 Insight Kunci dari EDA

- Distribusi severity mendekati seimbang karena menggunakan kuantil — tidak ada satu kelas yang sangat dominan.
- Mayoritas gambar memiliki 1–3 pothole; gambar dengan lebih dari 5 pothole termasuk kategori gambar kompleks.
- Distribusi bbox_area sangat skewed ke kanan (long tail) — sebagian kecil pothole berukuran sangat besar.
- Relative_size memberikan normalisasi yang lebih adil dibandingkan bbox_area mentah, terutama karena resolusi gambar bervariasi.
- Mayoritas gambar berada dalam kategori Sharp atau Moderate; hanya sebagian kecil yang masuk kategori Blur dan dibuang.
- Korelasi tinggi antara bbox_width, bbox_height, dan bbox_area adalah wajar dan tidak memerlukan tindakan khusus.

6. Data Splitting & Augmentation

6.1 Strategi Splitting

Dataset dibagi menggunakan strategi berbasis `image_name` (bukan per bounding box) untuk mencegah data leakage — yaitu kondisi di mana gambar yang sama muncul di lebih dari satu split.

Split	Proporsi	Fungsi	Catatan
Train	70%	Pelatihan model	Termasuk data augmentasi
Validation	15%	Tuning hyperparameter	Tidak diaugmentasi
Test	15%	Evaluasi final (blind test)	Tidak diaugmentasi

6.2 Data Augmentation

Augmentasi hanya diterapkan pada training set menggunakan library `Albumentations`. Pipeline augmentasi dirancang untuk mensimulasikan kondisi lapangan yang bervariasi:

- `HorizontalFlip` ($p=0.5$) — simulasi kamera kiri/kanan
- `RandomBrightnessContrast` ($p=0.7$) — simulasi kondisi pencahayaan berbeda (siang/malam)
- `GaussNoise` ($p=0.3$) — simulasi noise sensor kamera
- `ShiftScaleRotate` ($p=0.5$) — simulasi guncangan dan variasi sudut kamera

Keamanan Augmentasi

Pipeline menggunakan `BboxParams` dengan `min_area=25.0` dan `min_visibility=0.1` untuk memastikan bounding box yang sangat kecil atau hampir seluruhnya terpotong setelah transformasi otomatis dihapus — mencegah label yang misleading.

7. Dashboard Streamlit

Dashboard interaktif dikembangkan menggunakan Streamlit dengan arsitektur modular. Dashboard terdiri dari tiga modul utama: `data_loader.py`, `visualizations.py`, dan `components.py` — semua dipanggil dari `app.py` sebagai entry point.

Halaman	Konten & Visualisasi
01 Overview	Ringkasan eksekutif: total anomali, prioritas kritis (severity > 20), average severity, distribusi severity chart.
02 Data Purification	Proses IQA: metrik data funnel (1740 raw → cleaned), algoritma Laplacian, sample gambar bersih.
03 Spatial Recon	Peta distribusi spasial posisi pothole di dalam frame kamera (scatter density plot).
04 AI Pipeline	Distribusi train/val/test split, sample gambar augmentasi, raw data table dengan conditional formatting.
05 Statistical Testing	Desain eksperimen A/B Testing: Welch's T-Test, T-Statistic, P-Value, kesimpulan otomatis.

7.1 Fitur Tambahan Dashboard

- Global Filter di sidebar: filter berdasarkan minimum severity score dan ukuran kerusakan.
- Export Maintenance Dispatch: tombol download CSV berisi pothole dengan `severity_score > 20` untuk keperluan prioritas perbaikan.
- Nerd Mode Toggle: tampilkan source code algoritma (Laplacian, Albumentations pipeline) langsung di dashboard.

7.2 Catatan Bug & Perbaikan yang Diperlukan

Bug #1 — Kolom Filter Tidak Konsisten

Sidebar menggunakan `df['pothole_size_category']` untuk filter, padahal setelah feature engineering kolom tersebut diganti menjadi `'severity_label'`. Perbaikan: ganti referensi `'pothole_size_category'` di `app.py` dengan `'severity_label'` dan sesuaikan pilihan filter dari `['Small', 'Medium', 'Large']` menjadi `['Ringan', 'Sedang', 'Parah']`.

Bug #2 — Folder Images Kosong

Folder `data/images/train`, `data/images/test`, dan `data/images/validation` di dalam ZIP tidak mengandung file gambar (hanya `.DS_Store`). Halaman 02 yang menampilkan sample gambar bersih tidak akan berfungsi tanpa gambar aktual. Solusi: sertakan subset gambar atau gunakan URL langsung ke Kaggle.

8. A/B Testing — Pengujian Hipotesis

8.1 Desain Eksperimen

A/B Testing diterapkan untuk memvalidasi bahwa proses random splitting menghasilkan distribusi severity score yang seimbang antara kelompok training (Kelompok A) dan testing (Kelompok B).

Metode	Welch's T-Test (tidak mengasumsikan varians yang sama)
Variabel Uji	severity_score (float)
Kelompok A	Data Training (split = 'train')
Kelompok B	Data Testing (split = 'test')
Alpha (α)	0.05
H0	Tidak ada perbedaan signifikan antara rata-rata severity score training & testing
H1	Ada perbedaan signifikan — indikasi bias pada pembagian data

8.2 Hasil Pengujian

T-Statistic	P-Value	Kesimpulan
0.7669	0.4436	H0 Diterima

Karena P-Value (0.4436) > Alpha (0.05), H0 diterima. Tidak terdapat perbedaan yang signifikan secara statistik antara rata-rata severity score data training dan testing. Dengan demikian, proses random splitting dapat dinyatakan menghasilkan distribusi yang cukup seimbang dan evaluasi model ke depannya dapat dipercaya.

9. Kesiapan Data untuk Model & YOLO Export

9.1 Checklist Kesiapan Data

Dataset dinyatakan siap untuk tahap pelatihan model object detection setelah melalui verifikasi pada aspek-aspek berikut:

- Kelengkapan Data — Tidak ada missing value pada kolom kritis (image_name, koordinat bbox, label).
- Validitas Bounding Box — Seluruh koordinat berada dalam batas dimensi gambar dan memiliki area > 0.
- Kebersihan Data — Tidak ada duplikasi, label kosong, atau nilai tidak valid yang tersisa.
- Ketersediaan Fitur — 18 fitur tambahan tersedia untuk analisis dan pelatihan model.
- Kualitas Gambar — Gambar blur (skor < 100) telah dibuang dari training set.
- Pembagian Dataset — Split 70/15/15 berbasis image_name (anti data leakage).
- Format YOLO — Anotasi dikonversi ke format normalized (class_id x_center y_center width height).

9.2 Struktur Output YOLO

Dataset final diekspor dalam dua format:

pothole_dataset_full.csv	Dataset lengkap semua split dalam satu file CSV
pothole_train.csv	Training set dalam format CSV
pothole_validation.csv	Validation set dalam format CSV
pothole_test.csv	Test set dalam format CSV
yolo_dataset/images/train/	Gambar training (original + augmented)
yolo_dataset/images/validation/	Gambar validation
yolo_dataset/images/test/	Gambar test
yolo_dataset/labels/train/*.txt	Anotasi YOLO untuk training set
yolo_dataset/labels/validation/*.txt	Anotasi YOLO untuk validation set
yolo_dataset/labels/test/*.txt	Anotasi YOLO untuk test set

10. Data Dictionary

Tabel berikut mendokumentasikan seluruh kolom/fitur yang terdapat dalam dataset final (pothole_dataset_full.csv) beserta deskripsi dan kegunaannya:

Kolom / Fitur	Tipe Data	Deskripsi & Kegunaan
image_name	object/string	Nama file gambar asal setiap anotasi
width	integer	Lebar gambar (piksel); untuk validasi koordinat & normalisasi YOLO
height	integer	Tinggi gambar (piksel); untuk validasi koordinat & normalisasi YOLO
label	object/string	Nama objek pada anotasi (pothole)
xmin / ymin	integer/float	Koordinat titik kiri atas bounding box
xmax / ymax	integer/float	Koordinat titik kanan bawah bounding box
bbox_width	integer/float	Lebar bounding box = xmax – xmin
bbox_height	integer/float	Tinggi bounding box = ymax – ymin
bbox_area	integer/float	Luas bounding box; fitur utama analisis ukuran & severity
image_area	integer/float	Luas keseluruhan gambar (width × height)
aspect_ratio	float	Rasio lebar terhadap tinggi bounding box
relative_size	float	Proporsi bbox_area terhadap image_area (dalam %)
center_x / center_y	float	Titik tengah bounding box; digunakan juga untuk konversi YOLO
pothole_count	integer	Jumlah objek pothole dalam satu gambar
severity_label	object/string	Kategori keparahan: Ringan / Sedang / Parah
class_id	integer	Label numerik kelas (0=Ringan, 1=Sedang, 2=Parah)
severity_score	float	Skor keparahan gabungan dari relative_size + pothole_count
blur_score	float	Ketajaman gambar (Variance of Laplacian)
image_quality	object/string	Kategori kualitas gambar: Blur / Moderate / Sharp
split	object/string	Pembagian dataset: train / validation / test
yolo_x / yolo_y	float	Koordinat pusat bounding box ternormalisasi (format YOLO)
yolo_w / yolo_h	float	Dimensi bounding box ternormalisasi (format YOLO)

11. Status Deliverable & Checklist Proyek

Tabel berikut merangkum status seluruh deliverable proyek berdasarkan checklist yang telah ditetapkan:

Status	Deliverable / Komponen
✓ Selesai	Mengumpulkan dan menganalisis permasalahan, menentukan satu solusi utama (StreetWatch — pothole detection).
✓ Selesai	Data Wrangling end-to-end: Gathering (KaggleHub), Assessing (struktur XML, shape data), Cleaning (missing values, duplikasi, validasi bounding box).
✓ Selesai	Mendefinisikan 5 pertanyaan bisnis yang dapat diukur.
✓ Selesai	Exploratory Data Analysis (EDA) — 8 sub-bagian (distribusi severity, class ID, pothole/gambar, bbox area, relative size, blur score, korelasi, ringkasan insight).
✓ Selesai	Visualisasi data dan explanatory analysis untuk menjawab pertanyaan bisnis.
✓ Selesai	Dashboard interaktif dengan Streamlit — 5 halaman (Overview, Data Purification, Spatial Recon, AI Pipeline, Statistical Testing).
✓ Selesai	Data Dictionary (27 kolom terdokumentasi).
✓ Selesai	Feature Engineering (aspect_ratio, relative_size, center_x/y, pothole_count, severity_label, class_id, severity_score).
✓ Selesai	A/B Testing dengan Welch's T-Test — ada di notebook (sel 14) dan halaman 05 dashboard.
✓ Selesai	Kesiapan data untuk model: YOLO format conversion, split 70/15/15, export CSV & folder YOLO.
⚠ Catatan	Dashboard: bug kecil — sidebar filter memakai kolom 'pothole_size_category' yang sudah diganti menjadi 'severity_label'; perlu diperbaiki.
⚠ Catatan	Dashboard: folder data/images/ kosong — halaman 02 (sample image visual) tidak akan tampil saat dijalankan tanpa data gambar.
○ Belum	Deployment ke Streamlit Cloud — belum dilakukan.
○ Belum	Laporan teknis komprehensif dalam format PDF/Word — dokumen ini.

11.1 Rekomendasi Tindak Lanjut

Berdasarkan hasil evaluasi, terdapat beberapa langkah lanjutan yang disarankan:

1. Perbaiki bug filter sidebar di app.py: ganti 'pothole_size_category' dengan 'severity_label' dan sesuaikan pilihan filter.
2. Sertakan subset gambar di folder data/images/ atau gunakan caching gambar dari Kaggle agar halaman 02 dashboard berfungsi.
3. Lakukan deployment ke Streamlit Cloud menggunakan pyproject.toml yang sudah tersedia di repository.
4. Lanjutkan ke tahap pelatihan model YOLOv8/YOLOv11 menggunakan dataset YOLO yang sudah siap.
5. Pertimbangkan penambahan Stratified Split berdasarkan severity_label untuk memastikan distribusi kelas yang lebih merata di tiap split.

12. Kesimpulan

Proyek StreetWatch telah berhasil membangun pipeline data science yang komprehensif dari tahap Problem Discovery hingga kesiapan data untuk pelatihan model object detection. Berikut adalah ringkasan pencapaian utama:

Aspek	Pencapaian
Data Wrangling	End-to-end: gathering, assessing, cleaning — menghasilkan dataset yang bersih dan valid
Feature Engineering	12 fitur baru termasuk sistem klasifikasi severity multi-class berbasis distribusi data
EDA	8 sub-analisis menjawab 5 business questions dengan visualisasi yang informatif
Dashboard	5-halaman Streamlit dengan filter interaktif, augmentasi visual, dan A/B testing
A/B Testing	Welch's T-Test memvalidasi keseimbangan split — P-Value 0.4436 (H0 diterima)
Output Model	Dataset YOLO 3-class (Ringan/Sedang/Parah) siap untuk pelatihan model object detection

Proyek ini meletakkan fondasi yang kuat untuk pengembangan model deteksi jalan berlubang berbasis computer vision yang dapat diterapkan secara nyata untuk meningkatkan efisiensi pemantauan infrastruktur jalan.